



华南理工大学

SOUTH CHINA UNIVERSITY OF TECHNOLOGY

学生研究计划(SRP)项目验收
项目成员个人结题报告

参加项目名称:	基于时序逻辑的人机交互控制方法研究
参加项目编号:	X202410561821
参加起止时间:	2024 年 4 月至 2025 年 3 月
指导教师姓名:	陈刚
指导教师所在学院:	吴贤铭智能工程学院
学生姓名:	陈梓浪
学生学号:	202264642457
学生手机号:	13660021792
学生所在学院:	吴贤铭智能工程学院
学生所学专业:	智能制造工程
填表日期	2025 年 4 月

教务处

制

2025 年 3 月

1. 项目背景与研究意义

随着机器人技术的迅速发展，其在工业制造、医疗辅助、家庭服务、老年护理等多个领域的应用需求日益增长。然而，机器人在执行复杂任务时仍面临任务理解困难、控制策略不灵活、人机交互不自然等诸多挑战。尤其在多步骤、多条件约束的复杂任务中，传统的任务描述方式缺乏清晰性与可解释性，难以满足对高效、直观任务控制的需求。

本项目以时序逻辑语言（Temporal Logic Language）为核心研究对象，探索其作为机器人任务描述与指导工具的可行性与优势。时序逻辑语言兼具自然语言的易理解性与形式语言的精确性，能够清晰表达任务执行的先后顺序、条件依赖及逻辑关系，从而为复杂任务建模提供了理想的桥梁。相比传统编程方式，它更具可解释性，也更便于非技术人员参与任务规划，有效拓宽了机器人技术的适用群体和应用场景。

在此基础上，本项目引入深度学习技术以实现时序逻辑语言的自动解析与任务执行。深度学习在处理复杂模式识别与决策问题方面具有显著优势，能够使机器人对时序逻辑任务具有更高的理解能力与执行效率。通过将深度学习与形式逻辑语言结合，机器人不仅能够理解复杂的任务结构，还能在动态环境中灵活应对任务变化，显著提升了任务执行的准确性与适应性。

此外，本研究还致力于创新人机交互方式，通过将具备逻辑表达能力的任务描述语言与深度学习相结合，为用户提供一种更自然、直观的机器人交互与控制方法。这种新型交互方式不仅提升了人机协作的效率，也增强了机器人系统的可用性和用户体验，具有广泛的应用前景。

综上所述，本项目的研究工作在理论和实践层面均具有重要意义：一方面为机器人任务建模与控制提供了新的思路和工具，推动了机器人智能化水平的提升；另一方面也为人类与机器人之间的自然交互开辟了新的路径，为机器人技术在更广泛领域的推广应用提供了坚实基础。

2. 文献调研

传统的任务编程方法在描述多步骤、条件依赖性强的任务时常显得笨重且不直观，限制了非技术用户对机器人系统的理解与控制能力。为此，近年来学界开始关注时序逻辑语言（Temporal Logic Language）在机器人任务建模与执行中的潜力。

时序逻辑语言以其良好的形式化特性，能够清晰地表达任务执行的先后顺序、条件依赖及逻辑结构，在精确性与可解释性方面均优于传统任务描述方式，尤其适用于复杂任务的建模与自动化执行。

与此同时，深度学习技术作为当前人工智能领域的重要方法，在图像识别、语义解析、自然语言处理等方面取得了显著成果，其强大的模式识别与决策能力使其成为实现任务自动解析与执行的理想工具。

综上所述，国内外研究者开始探索将深度学习与时序逻辑语言结合，以构建具备智能感知与逻辑推理能力的机器人控制系统，进而实现更自然、直观的人机交互方式。

以下将围绕时序逻辑语言的理论基础、其在机器人领域中的应用现状、深度学习在任务解析与控制中的优势及融合机制，以及人机交互方式的最新研究进展等方面展开文献调研。

2.1 LCRL

该研究介绍了一种用于策略合成的新型工具——LCRL（Logically-Constrained Reinforcement Learning），该工具结合了模型无关的强化学习算法与线性时序逻辑（LTL）约束，实现了在未知马尔可夫决策过程（MDP）中合成满足 LTL 规范的最优策略。LCRL 通过将 LTL 公式转化为限制性确定的 Büchi 自动机（LDBA），在 RL 训练过程中实时塑造奖励函数，指导智能体向满足规范的轨迹学习。其核心优势在于：无需了解 MDP 的转移模型，仅依赖执行轨迹即可学习策略；此外，LDBA 结构为探索过程提供方向性，有效避免了状态空间的盲目遍历，从而提高了学习效率和收敛速度。




图 2.1.1 LCRL 架构

LCRL 的主要贡献包括：（1）实现了在连续状态与动作空间中基于 LTL 规范的策略学习，是当前唯一支持该特性的 RL 工具；（2）在多个复杂任务（如 Minecraft 任务、Pacman 游戏、mars-rover 机器人任务等）上展示了出色的泛化性与鲁棒性；（3）具有良好的超参数稳定性，在不同学习率和折扣因子的设定下依然保持较高的 LTL 满足概率。实验证明 LCRL 在高维任务中依然保持可扩展性，且在某些任务中能与模型检查工具 PRISM 所验证的最优策略相媲美。




图 2.1.2 (a) LCRL 在 minecraft-t3 环境中合成的策略；(b) cart-pole(倒立摆)实验 [44]；
(c) pacman-lrg

相较于现有的强化学习合成工具，LCRL 克服了许多限制，例如部分工具仅支持有限 LTL 片段或需依赖已知模型。LCRL 则通过结合 LDBA 的非确定性转移机制和 RL 学习架构，能在线处理 ϵ -转移并动态同步任务规范与环境状态。此外，LCRL 提供模块化的 Python 接口，支持多种 RL 算法（如 Q-learning、NFQ、DDPG），便于用户根据任务特性灵活选择。

综上，LCRL 不仅为复杂逻辑任务提供了形式化的策略学习方法，还具备良好的扩展潜力与工程应用价值。未来的发展方向包括引入更多类型的时序逻辑（如信号时序逻辑）、拓展图形界面以及与自动机合成工具和模型检查器的集成等。但它也存在若干缺陷，特别是在人机交互场景中应用时，暴露出一些局限性：

缺乏即时交互与自适应机制：LCRL 在训练过程中为离线学习为主，学习时间长，每次交互策略都需预先训练收敛，对于实时更新交互策略的场景（如适应新用户习惯）并不灵活。

不可解释性问题依然存在：尽管引入 LDBA 提升了对任务规范的追踪能力，但学习到的策略仍基于 Q 函数的“黑箱”决策，不具备良好的可解释性，这在 HCI 中尤为重要——人类需要理解和信任机器的行为逻辑。

在测试后我们认为这种模型不利于我们后续研究，故在此做借鉴作用，不作进一步研究。

2.2 E-LDGBA-LTL

本研究提出了一种基于强化学习（RL）的模型自由方法，用于在存在不确定性情况下最大化线性时序逻辑（LTL）任务满足概率的控制策略合成。文章的核心贡献在于通过引入嵌入式限制确定性广义 Büchi 自动机（E-LDGBA），将复杂任务规范转换为便于强化学习处理的形式，从而克服了传统 LTL 控制方法在处理无限时域问题及稀疏奖励问题中的限制。




图 2.2.1 (a) 带有确定性标签函数的 PL-MDP (概率标记马尔可夫决策过程) 模型。(b) LTL 公式 ϕ_e 的 LDGBA。(c) 标准乘积 MDP (马尔可夫决策过程)

研究将机器人系统建模为具有未知转移概率和标签不确定性的概率标记马尔可夫决策过程 (PL-MDP)。为了处理 LTL 规范, 该方法使用 E-LDGBA 与 PL-MDP 构造出嵌入式产品马尔可夫决策过程 (EP-MDP), 并设计了同步前沿追踪函数用于记录尚未访问的接受集。该方法确保在强化学习过程中奖励足够密集, 从而加快策略的收敛, 并保证最终策略能够以最大概率满足 LTL 规范。




图 2.2.2 对应最优策略下的 25 个时间步的模拟轨迹。

在理论方面，文章推导了在适当设置的折扣因子条件下，强化学习所得的最优策略能够保证最大化满足概率。此外，为了处理实际中的环境与动作不确定性，作者还在仿真和真实机器人系统中进行了实验验证。实验包括有限网格世界中的路径规划任务和 TurtleBot3 在 ROS Gazebo 中的多房间巡检任务。结果表明，与传统的 LDBA 方法相比，E-LDGBA 策略在奖励密度和任务满足率方面均有显著提升。

此外，本文在处理无限时域、多接受集、确定性策略生成等问题中提供了系统性解决方案，为复杂任务规范下的 RL 策略合成提供了理论和实践基础。未来工作将探索如何将该方法扩展至连续状态和动作空间下的深度强化学习框架中。

该模型虽然在形式化任务规划中具有理论优势，适合应用在机器人自动任务执行与安全策略验证等领域，但仍存在**策略学习效率低，适应性差**，稀疏奖励问题仍未根本解决，依赖于已知**马尔可夫决策过程（MDP）**的问题：

策略学习效率方面，强化学习基于与环境的长时间交互，策略收敛过程缓慢，且模型基于模型无关（model-free）策略，对动态变化环境和交互意图响应缓慢。而在人机交互场景中，系统需要快速适应用户输入，而此方法并不擅长处理这些快速切换场景。

对于稀疏奖励问题，虽然通过 E-LDGBA 增强了奖励密度，但相比典型 HCI 系统对反馈响应的即时性要求，它仍属于训练过程中较难获得有效反馈的问题类型，学习过程依赖大量重复试错。

依赖于已知马尔可夫决策过程（MDP）则导致了在实际任务中难以进行精细坐标移动，与我们的研究目标不符。

综上所述该模型与我们的目标上存在偏差，具有借鉴价值而没有适用价值。

2.3 Modular_Deep_RL_E-LDGBA

该研究在 E-LDGBA 的基础上，旨在解决连续状态与动作空间中具有不确定动态的自主系统运动规划问题，提出一种结合线性时序逻辑（LTL）任务规范与深度强化学习的模块化方法。文章从马尔可夫决策过程（MDP）出发，引入了嵌入式积产品 MDP（EP-MDP）的新型建模方式，通过同步跟踪未访问接受集合的机制，有效地辅助 LTL 规范的满足。

传统基于 LTL 的运动规划多依赖于已知的 MDP 模型，或采用模型学习的方法，但存在模型规模膨胀和稀疏奖励的问题。本文采用一种模型无关的强化学习方法，通过将 LTL 任务转化为具有多个接受集合的限制性确定性广义 Büchi 自动机（LDGBA），并构建 EP-MDP 结构，将复杂任务拆解为可学习的子模块，配合任务引导的奖励设计提升训练效率。

核心贡献在于：

- 引入 EP-MDP 结构记录未访问的接受集合，保证任务在每一轮中完整满足 LTL 接受条件；
- 提出基于势函数的奖励塑形机制，缓解稀疏奖励问题，同时保持最优策略不变性；
- 构建模块化 DDPG (Deep Deterministic Policy Gradient) 结构，使每个 LDGBA 状态对应一组 actor-critic 网络，提升任务学习的稳定性与可解释性。




图 2.3.1 (a) Ball-Pass 和 (b) CartPole




图 2.3.2 火星探测任务中 Melas Chasma 及其可能存在水的位置（蓝色点表示），(a) (b) 为不同初始位置下的轨迹

实验部分分别在 Ball-Pass、CartPole 以及基于图像的火星探测任务中验证方法效果。与标准 DDPG 以及非 EP-MDP 方法相比，该方法在任务完成率上具有显著优势，尤其在 LTL 具有重复访问模式（即无限时域）下表现更为优越。

总体而言，该研究在理论建模和算法实现上提供了新颖而有效的解决思路，适用于复杂时序任务的强化学习，特别是具备连续状态与动作空间的实际应用情境，为未来的机器人任务规划与自主系统控制提供了坚实基础。

这篇论文所提出的模型在强化学习与形式化方法结合方面具有很强的理论支撑和实证表现，然而，其同样存在着实时性弱，难以适应在线决策需求的关键

性缺陷，以及计算资源开销大，训练效率低的新问题。模块化 DDPG 结构需要为 LDGBA 中每个状态都配置独立的 actor-critic 网络。这在面对状态数量较多的复杂任务时，显著增加训练成本和存储开销，该模型并不适用。

2.4 Synthesis Based Repair

本研究围绕机器人在执行复杂、高层次任务时的可行性修复问题展开，重点探讨如何在给定技能集不足以完成目标任务时，通过线性时序逻辑（LTL）进行任务规格的符号修复，并结合物理可行性校验，使机器人能够成功执行原本不可实现的任务。该方法针对两个关键假设进行了放宽：（1）传统方法只考虑技能执行前后的状态，而忽略中间过程；（2）默认给定的技能足以完成任务。然而现实中技能执行过程中可能违反安全约束，而技能集本身也可能不完备。




图 2.4.1 Synthesis Based Repair 任务编码与修复方法的概述

为此，作者将技能以 GR(1)形式的 LTL 公式编码，不仅包含前后状态，也显式表示中间状态，从而更好地捕捉执行过程中的潜在风险。例如，机器人搬运水杯穿越电子设备的场景，仅考虑始末状态可能会忽略中间穿越的风险。作者提出的修复机制分为“符号修复”和“物理可行性实现”两阶段，二者间具有反馈机制：若物理实现不可行，则生成新的约束反馈至符号修复过程。




图 2.4.2 Symbolic-Physical Repair 的步骤

该方法融合了正式方法、任务-动作规划（TAMP）、以及基于 LTL 约束的强化学习方法。相较于以往修复方法多限制环境行为，本文的亮点在于通过修改技能本身实现任务修复。此外，作者通过 Baxter 机械臂和 Clearpath Jackal 移动平台进行了实际演示，验证了所提方法在不同物理系统和任务抽象下的通用性。

该研究的主要贡献包括：（1）提出了能体现执行中间状态的技能编码方式；（2）构建了符号与物理层面的修复框架；（3）展示了多个实例，涵盖技能前提修改、后效修正、中间状态调整等多种修复场景。总之，本文为具备复杂反应性任务的机器人规划提供了一种自动化、可实施的修复机制，具有重要的理论与应用价值。

该方法虽仍具有学习能力有限，所有修复均依赖于已有技能的变体等问题，但较为切合我们的研究目标，遂决定在借鉴研究的基础上继续我们的研究。

3. 研究方案

3.1 整体思路与技术路线

本项目围绕“基于时序逻辑的人机交互控制”这一主题展开，采用将形式化时序逻辑与机器人路径规划技术相结合的思路，以提高复杂任务的人机交互控制效

率和可靠性。我们首先进行了充分的文献调研并选择两篇具有代表性的研究工作进行复现，以汲取现有方法的精华并发现其局限。在此基础上，我们设计了自己的技术路线：由用户采用时序逻辑语言描述任务规范，系统将其转化为可执行的机器人动作序列和路径规划方案。如果初始任务规范因技能限制无法直接实现，我们引入“基于时序逻辑的任务修复”机制对规范进行自动修改。整个控制流程基于 ROS2 机械臂仿真平台实现，通过多场景实验验证方法的有效性，并根据评估指标不断优化算法性能。最后，我们展望了将该方法拓展到无人机等自主平台的可能性，并制定了后续研究计划以检验方法的通用性。

3.2 文献复现的背景与用途

项目初期我们选取了两项关键文献成果进行深入研究和算法复现：

(1) LCRL (Logically-Constrained Reinforcement Learning) 工具 ——这是一种将线性时序逻辑约束融入强化学习的策略合成方法。LCRL 能够在未知环境的连续状态-动作空间中学习满足 LTL 规范的最优策略。我们复现 LCRL 的目的在于了解如何利用强化学习来处理复杂时序任务，并考察其在实时人机交互场景中的适用性。复现过程中，我们运行了论文中的典型案例（如 Minecraft 任务、Pacman 游戏等）以验证 LCRL 的泛化性能。通过实验我们发现，LCRL 虽然在复杂逻辑任务上取得了较好效果，但其**主要局限**在于策略学习耗时长、交互实时性差，难以满足人机交互对即时响应的需求。因此，我们将 LCRL 的方法作为参考借鉴，而未直接采用于本项目。（<https://github.com/grockious/lcrl>）




图 3.1 LCRL 测试截图

(2) “Synthesis-Based Repair”任务修复方法 ——这项研究提出了当机器人技能库不足以完成高层次任务时，利用线性时序逻辑对任务规格进行符号层面的自动修复，并结合物理可行性验证来确保修复后的任务可执行。我们复现该方法是因为其理念契合我们的目标：既关注任务规范的形式化表达，又能在技能受限情况下调整任务以保证完成。通过阅读源码和实验重现，我们深入理解了符号修复和物理层验证的实现机制，例如如何将技能编码为 GR(1)形式的 LTL 公式，以及符号修复与运动规划之间的反馈迭代过程。复现结果表明该方法可以在不同平台（如 Baxter 机械臂、Jackal 移动机器人）上通用地修正任务规范，为我们后续设计自己算法提供了重要参考 (https://github.com/apacheck/synthesis_based_repair)




图 3.2 Synthesis-Based Repair 算法研究成果展示

综上，两篇文献的复现让我们掌握了深度强化学习+时序逻辑和符号规划修复这两类前沿技术，为本项目方案的制定打下基础。

3.3 时序逻辑与路径规划结合的方法

综合文献复现收获，我们提出了一种将线性时序逻辑(LTL)任务规范与机器人路径规划相融合的控制方法。

首先，用户以时序逻辑公式形式给出任务意图（例如：“先执行 A，再执行 B，同时始终避免条件 C”）。系统将该 LTL 任务规范解析为对应的自动机表示或任务脚本，并判断现有机器人技能和环境能否直接满足规范。如果直接可行，我们使用路径规划算法生成满足规范的运动轨迹；若发现任务因约束冲突或技能缺失不可行，则启动任务规范修复模块：基于“Synthesis-Based Repair”思想，对原任务规约进行调整或细化。例如，添加额外步骤绕过危险区域，放宽某些顺序约束等，使修改后的规范在满足核心意图的同时变得可执行。

接下来，在得到可行的任务序列后，我们采用机器人运动规划算法（如基于采样的 RRT 或基于搜索的 A 等）计算机械臂从初始状态到目标状态的具体路径在规划过程中，我们将 LTL 规范细化为路径约束（例如特定动作的顺序、访问区域的顺序限制、避障要求等），确保生成的轨迹不违反任务逻辑要求。该方法

相当于结合任务-动作规划（TAMP）与时序逻辑约束：高层由 LTL 把关任务序列的正确性，低层由路径规划保证物理运动的可达性。这种双层结合既保证了任务执行的逻辑严谨性，又兼顾了机器人运动的可行性与优化性。当路径规划失败时，系统会将失败原因（例如某路径段不可行）反馈给任务修复模块，进一步调整任务规范，形成闭环。

经过若干迭代，最终产出一条既满足时序逻辑规范、又能够由机器人实际执行的安全路径和动作序列。我们的方法以形式化逻辑为核心指导，实现了从“人类任务意图（逻辑表达）”到“机器人执行计划（运动控制）”的自动转换，为人机交互提供了高层次指令到低层运动的桥梁。

3.4 ROS2 机械臂建模与实现

为了验证上述方法，我们搭建了基于 ROS2 的机械臂仿真与控制平台。我们选取通用的工业机械臂模型（如 ABB IRB1200 或 UR5 机器人），通过 ROS2 的 MoveIt 运动规划框架和 Gazebo 仿真环境，对机械臂的运动学和动力学进行建模。参考开源项目“ROS Industrial Simple Motion Control”(https://github.com/rparak/ROS_Industrial_Simple_Motion_Control)，我们编写了 ROS2 节点和配置文件，实现机械臂的关节空间控制、轨迹规划以及与 Rviz 可视化界面的交互。

具体而言，我们利用 ROS2 发布/订阅机制控制机械臂各关节的运动，并通过 MoveIt 规划器计算无碰撞的轨迹。在环境建模方面，我们在 Gazebo 中构建了实验场景，包括机械臂、本体工作台、目标物体以及障碍物等，使仿真环境尽可能贴近真实情况。为了融入我们的时序逻辑控制策略，我们开发了一个**中间层接口**：该接口一方面接收高层任务规划模块输出的动作指令序列（例如“抓取物体 X”“移动至区域 Y”），另一方面调用 ROS2 底层运动控制，实现每条指令对应的机械臂实际动作。

通过该接口，我们成功将形式化任务规划与 ROS2 物理仿真对接：当高层规划确定下一步动作时，ROS2 机械臂立即执行相应动作，并将执行结果（如是否

达到目标位置、传感器状态变化等) 反馈给高层, 以验证时序逻辑约束是否满足。这种架构确保了算法仿真闭环的流畅运行, 使我们能够在虚拟环境中演示复杂任务的自动化执行。例如, 在“先取物再放置且避开危险区”的任务中, 高层规划先后下达“抓取 A”“避开区域 B 移动到 C”“放置 A 于 C”等指令, 每一步指令通过 ROS2 均得到平滑执行, 机械臂轨迹清晰可见, 验证了系统的有效性。




图 3.3 moveit 示例

3.5 后续研究目标:

3.5.1 多场景实验设计与评估指标

我们将设计**多种场景**来测试所提出方法的通用性和鲁棒性, 每个场景均对应不同类型的时序逻辑任务和环境配置:

场景 1: 顺序任务场景。 机械臂需按指定顺序操作多个物体 (如依次拾取红色方块然后蓝色方块), 我们使用 LTL 公式描述顺序约束并规划路径。评估指标包括任务**顺序遵守率** (机械臂是否严格按照要求顺序完成动作)、轨迹长度和用时等。

场景 2: 避障安全场景。 机械臂执行搬运任务, 中途必须绕过特定危险区域或障碍物。例如“始终避开区域 X”。我们评估**安全约束满足率** (机械臂运动

是否违反避让约束）、最近距离裕度（与障碍保持的最近距离，以验证安全性）以及规划开销（计算轨迹所需时间）。

场景 3：技能不足修复场景。 在此场景中，我们故意从任务规范中移除某个必要动作，导致机械臂按原规范无法完成任务。系统需自动修复任务规范（例如加入中间步骤或更换动作顺序）。我们关注**任务成功率**（最终是否完成任务）、**修复次数**（自动调整规范的迭代次数）以及每次修复耗时等指标，来评估任务修复模块的效率和有效性。

场景 4：动态交互场景（扩展实验）。 模拟人机交互过程中的临时指令改变或环境变化。例如任务执行中途用户插入新的次要任务。我们观察系统的**响应时间**（从指令变更到重新规划的延迟）和**任务完备性**（新的指令和原任务是否均被完成），以衡量本方法在交互场景下的适应性。

针对以上场景，我们将综合采用定量和定性指标进行评估。一方面，通过**量化指标**如成功率、违约（违反规范）次数、轨迹优化度（路径最短距离相对于直线距离的比值）、规划计算时间等衡量算法性能；另一方面，通过**定性观察**机械臂在仿真中的行为（如运动是否平稳、是否出现异常停滞或震荡）来判断控制策略的可靠性。

3.5.2 后续拓展计划：

鉴于本项目方法在机械臂平台上的效果，我们计划在后续工作中将该算法拓展至**无人机**等其他自主机器人平台，以验证方法的通用性和扩展能力。无人机具有运动空间为三维、动力学约束复杂、速度快等特点，在其上应用时序逻辑控制需要克服新的挑战。例如，我们需要考虑无人机的姿态稳定和飞行安全约束（如“始终保持一定高度以上”或“在进入某区域前必须完成拍照”之类的时序任务）。为此，我们将借鉴开源项目中的轨迹跟踪控制器 (https://github.com/Zhefan-Xu/tracking_controller) 来实现无人机的底层运动控制，并将本项目的高层任务规划模块对接到无人机 ROS 飞控系统（如 PX4）上。

具体设想包括：让无人机在给定环境中按照 LTL 描述执行巡航任务（如定期巡视多个点并避开禁飞区），利用我们的方法自动规划飞行路线和任务顺序。如

果遇到无法直接完成的高层指令（例如某个巡检点无法抵达），则由系统自动调整巡航顺序或加入中继航点，确保任务完成。我们将针对无人机的特点引入新的评估指标，如轨迹平滑度、能源消耗以及飞行器状态约束满足情况等，对算法进行评估和必要的优化调整。

通过上述拓展，我们期望验证本项目所提“时序逻辑+路径规划”框架在空中机器人领域同样适用，从而为多平台的一体化人机交互控制奠定基础。

4. 组内分工情况

本项目由两名成员合作完成。我们在导师的指导下采取了明确分工与紧密协作相结合的工作方式，以发挥各自特长、提高研发效率。具体分工情况如下：

张迪桑：主要负责算法研究与实现方面的工作。一方面，承担了关键文献方法的复现与改进（重点复现“**Synthesis-Based Repair**”符号修复算法，并分析 LCRL 工具的适用性），为本项目奠定算法基础；另一方面，负责将时序逻辑规划算法与 ROS2 机械臂控制进行集成，实现从高层逻辑指令到低层运动控制的转换。这包括编写任务规划模块代码、设计 LTL 到动作序列的映射机制，以及开发 ROS2 节点控制机械臂运动等。

陈梓浪：主要负责系统平台搭建与实验测试方面的工作。承担了 ROS2 仿真环境和硬件模型的搭建，包括机械臂模型的导入、Gazebo 场景构建以及传感器/控制接口的配置，确保实验平台可靠可用。同时，复现并测试了 LCRL 强化学习方法，在仿真环境中运行典型案例以评估其性能，为研究提供对比参考。侧重于底层控制与环境交互，例如编写 ROS2 节点来模拟传感器反馈、实现机械臂抓取放置等基础功能模块；并协助将高层规划结果与仿真环境对接，比如搭建消息通信机制来触发机械臂动作。

协作方式方面，我们定期交流进展，共同调试程序。例如，在集成过程中若出现机械臂运动不符合预期的情况，共同排查问题——检查高层逻辑和任务规划代码，ROS 话题通信和机械臂控制参数，通过配合顺利解决问题。通过明确分工和良好合作，双方相互配合、优势互补。

5. 本人主要工作与成效

5.1 算法复现与模块开发

在项目初期，我首先针对文献中的关键算法进行了复现和二次开发。其中最重要的模块是“基于时序逻辑的任务规范修复与规划”算法。

首先，针对文献调研阶段我们搜寻的论文与算法，我选取了最终总结的对于我们项目最有借鉴价值的项目：E-LDGBA-LTL，LCRL 和 Synthesis Based Repair 三个项目进行复现与探究。

5.1.1 LCRL

该模型是一种将线性时序逻辑约束融入强化学习的策略合成方法，能够在未知环境的连续状态-动作空间中学习满足 LTL 规范的最优策略。我们复现 LCRL 的目的在于了解如何利用强化学习来处理复杂时序任务，并考察其在实时人机交互场景中的适用性。复现过程中，我们运行了论文中的典型案例 Minecraft 任务以验证 LCRL 的泛化性能：




图 5.1.1 . 1 LCRL 典型案例 Minecraft 任务测试，目标要求先抵达 gold 方块后抵达 tool_shed 方块

该研究为我们提供了初步的设计思路。但测试后我发现该算法的成功概率过低，平均 3 到 4 次测试中才有一次成功，且长距离寻路成功概率更低。在加上障碍后，更是 14 次才成功寻路完成了第一次。且由于训练需要两至三分钟才完成一次训练，缩短训练步数会导致任务成功率大幅下降。在多番考虑后，我们放弃了直接使用该模型，转而寻找优化过的模型方案。

5.1.2 E-LDGBA-LTL

该模型在 LCRL 的基础上，将复杂任务规范转换为便于强化学习处理的形式，以克服了传统 LTL 控制方法在处理无限时域问题及稀疏奖励问题中的限制。根据其 GitHub 开源吧代码，我们对该模型进行了测试：




图 5.1.2.1 E-LDGBA-LTL 示例程序测试结果，程序要求从[1,8]点开始，在抵达蓝色区块后抵达黄色区块




图 5.1.2.2 E-LDGBA-LTL 自定义障碍后测试结果

经过测试，我发现，该模型对少障碍寻路有着优秀的性能，成果概率接近百分百，但对于削减寻路长度方面则不甚理想，仍然存在无意义绕路等问题。同时，在进行大障碍物寻路中，成功概率则大幅度降低，若起点较为靠近障碍物的情况下，平均需要 5 到 6 次测试才能成功一次，对复杂环境的寻路更是概率极低。该模型还有着训练时间长的问题。在讨论后，我们放弃了该方法。

5.1.3 Synthesis-Based Repair

该研究围绕机器人在执行复杂、高层次任务时的可行性修复问题展开，重点探讨了在给定技能集不足以完成目标任务时，如何通过线性时序逻辑（LTL）对任务规格的符号进行修复，并结合物理可行性进行校验，使机器人能够成功执行原本不可实现的任务。

根据 GitHub 上的开源代码，我们对其示例程序进行了复现：




图 5.1.3.1 物理修复过程步骤：第一列展示了原始技能的采样轨迹，第二列展示了成功实现 skill 修改的采样轨迹，第三列展示了失败的采样轨迹；第一排是开始修复时的采样轨迹，第二排是修复 20 步后的采样轨迹，第三排是修复完成后的采样轨迹。

经过测试，该模型可以有效的通过物理修改 skill 来达到避免具体区块，到达目的地。该方法虽仍具有学习能力有限，所有修复均依赖于已有技能的变体等问题，但较为切合我们的研究目标。

最终我们决定在借鉴 Synthesis-Based Repair 研究的基础上继续我们的研究。

5.2 Synthesis-Based Repair 算法的进一步研究与应用

根据“Synthesis-Based Repair”方法，我用 Python 实现了一个两阶段的任务规划框架：

(1) **符号修复阶段**：将机器人技能和任务要求形式化为 LTL 公式，利用 GR(1)规约合成技术构建任务自动机，并编写算法自动检查任务规范的可实现性。如检测到因技能限制或安全约束导致规范不可实现，我的程序会定位出冲突的约束或缺失的步骤，然后按照文献提供的策略进行修复——例如，在任务序列中插入中间步骤以绕过危险操作，或调整某些动作的先后顺序满足前置条件。这一部分需要深入理解 LTL 语义和自动机算法，我通过阅读文献，调试自动机生成代码，成功让程序能够输出**修改后的可行任务 LTL 规范**。

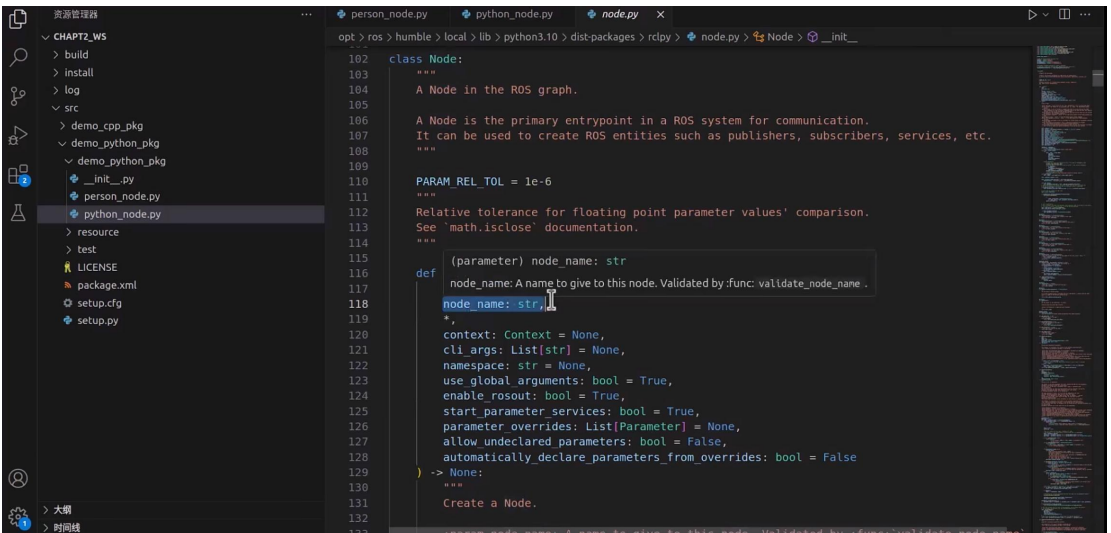
(2) **物理可行性验证阶段**：针对符号阶段给出的任务序列方案，我开发了一个物理层检查模块。该模块调用运动规划库（MoveIt）尝试为每一步动作生成可行的轨迹。如果某一步规划失败，程序将捕获失败原因（例如路径被障碍物阻挡、目标超出机械臂工作空间等），并将此信息转换为约束反馈给符号阶段进行二次修复。为实现这一闭环，我设计了清晰的接口协议：符号规划模块输出动作序列及关键状态，中间通过 ROS 服务调用运动规划，运动规划返回执行可行性和环境反馈。经过多次迭代开发与测试，我实现的算法模块可以自动在符号层和物理层之间来回调整，最终产出既满足时序逻辑约束又切实可执行的动作计划。这一自主规划模块是本项目的方法核心，我在实现过程中注重模块化设计，将 LTL 任务解析、自动机生成、策略修复、路径搜索等功能解耦为独立子模块，使得算法具有良好的扩展性。在调试完成后，我对比了复现算法和原文结果，确认我的实现

正确再现了文献中的示例场景(如 **Baxter** 机器人搬运水杯绕过电子设备的案例)，为后续与 ROS2 集成做好了准备。

5.3 算法与 ROS2 平台接轨实现路径规划控制

在完成高层算法模块后，我将精力集中在将该模块无缝衔接到 ROS2 机器人控制平台上，真正让机械臂“听懂”时序逻辑指令并动起来。这部分工作涉及将抽象的任务规划结果翻译为具体的机器人控制命令，并确保在 ROS2 框架下实时执行。我主要完成了以下几个技术环节：

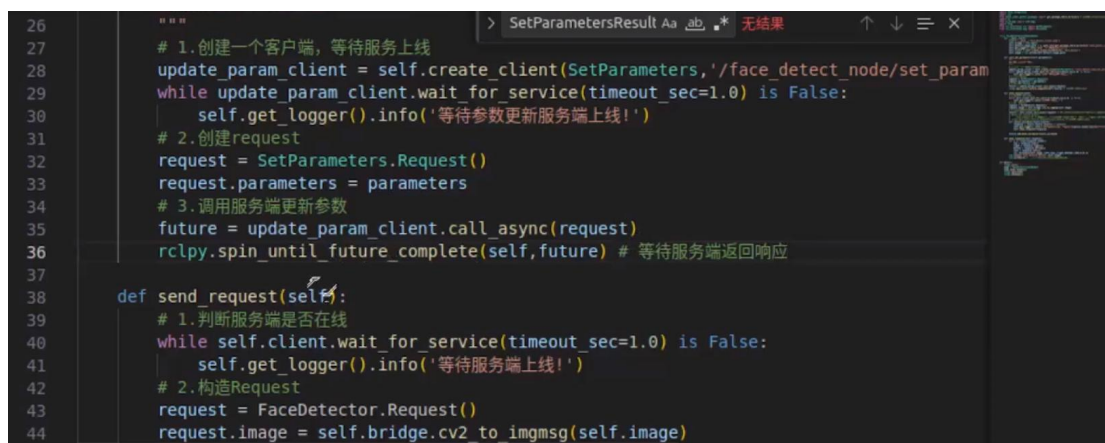
机器人动作接口开发： 我编写了 ROS2 节点（使用 rclpy Python 接口），订阅高层任务规划模块发布的动作序列消息。每当高层模块确定下一步动作（例如“移动机械臂到位置 P”或“抓取物体 O”），节点将解析该动作指令，通过调用 ROS2 的服务/话题接口，触发对应的机械臂运动。例如，针对“移动到位置 P”，节点调用 MoveIt 的运动规划服务为机械臂末端生成一条到达目标位置 P 的轨迹，然后发布关节控制指令；针对“抓取物体 O”，节点控制机械臂末端执行夹爪关闭动作并检查握持成功与否。通过这样的节点，我构建了从时序逻辑动作到机械臂底层控制的桥梁，使高层规划结果能够驱动实际机器人动作。



```
102 class Node:
103     """
104     A Node in the ROS graph.
105
106     A Node is the primary entrypoint in a ROS system for communication.
107     It can be used to create ROS entities such as publishers, subscribers, services, etc.
108     """
109
110     PARAM_REL_TOL = 1e-6
111     """
112     Relative tolerance for floating point parameter values' comparison.
113     See 'math.isclose' documentation.
114     """
115
116     (parameter) node_name: str
117     node_name: A name to give to this node. Validated by func: validate_node_name.
118     node_name: str,
119
120     *,
121     context: Context = None,
122     cli_args: List[str] = None,
123     namespace: str = None,
124     use global arguments: bool = True,
125     enable_rosout: bool = True,
126     start_parameter_services: bool = True,
127     parameter overrides: List[Parameter] = None,
128     allow undeclared parameters: bool = False,
129     automatically declare parameters from overrides: bool = False
130 ) -> None:
131     """
132     Create a Node.
```

图 5.3.1 rclpy 节点编写

状态监测与反馈： 为了让高层算法了解动作执行情况（从而判断 LTL 任务是否满足），我利用 ROS2 的发布/订阅机制监测机械臂及环境状态。例如，在抓取动作执行后，传感器话题会反馈夹爪压力值和物体是否拿起，我的节点会将“物体 O 已被抓取”的事实反馈给高层任务状态；在移动动作执行过程中，实时监控机械臂关节状态，当到达目标位姿后，反馈“已到达位置 P”。这些反馈通过我设计的信息格式发送回高层规划模块，从而更新 LTL 自动机的当前状态，使高层能够据此决定下一步动作。这种闭环控制保证了高层逻辑与底层执行的一致性：每完成一步，系统都会验证相应的时序逻辑原子命题是否满足，如未满足则可以触发异常处理（比如重新规划）。



```
26
27
28 # 1. 创建一个客户端，等待服务上线
29 update_param_client = self.create_client(SetParameters, '/face_detect_node/set_param')
30 while update_param_client.wait_for_service(timeout_sec=1.0) is False:
31     self.get_logger().info('等待参数更新服务端上线!')
32 # 2. 创建request
33 request = SetParameters.Request()
34 request.parameters = parameters
35 # 3. 调用服务端更新参数
36 future = update_param_client.call_async(request)
37 rclpy.spin_until_future_complete(self, future) # 等待服务端返回响应
38
39 def send_request(self):
40     # 1. 判断服务端是否在线
41     while self.client.wait_for_service(timeout_sec=1.0) is False:
42         self.get_logger().info('等待服务端上线!')
43     # 2. 构造Request
44     request = FaceDetector.Request()
45     request.image = self.bridge.cv2_to_imgmsg(self.image)
```

图 5.3.2 服务端信息接收与参数更新

时序与并发处理： 在 ROS2 接轨过程中，我还处理了实际系统中的时序和并发问题。比如机械臂执行动作需要时间，高层规划不能在此期间停滞等待，否则会降低交互响应性。为此，我采用异步方式执行底层动作：高层下达指令后继续运行下一个逻辑判断，而底层节点异步监听完成信号。一旦动作完成或失败，立即通过回调更新高层状态。这种设计提高了系统并发性能。此外，我注意到某些情况下高层可能同时发出多个约束（如“期间保持条件 C 为真”这种持续性约束），为了处理此类并行要求，我在底层增加了监视线程，持续检查环境中条件 C 是否违反，一旦检测到违反则及时通知高层暂停当前计划并进行修正。通过这些机制，我使整个系统在 ROS2 平台上运行时能够满足**实时控制**的需求，支持一定程度的并行与异步，贴近真实人机交互场景。

通过上述努力,我成功地将复杂的时序逻辑控制算法在 ROS2 机械臂平台上落地,实现了从任务规范到机器人行动的自动规划执行。这一成果在项目中期通过内部验收:机械臂能够根据预先设定的 LTL 任务公式完成一系列连贯动作,验证了算法-平台集成的正确性。

6. 成果体现:

系统原型演示: 开发并集成的整套系统实现可运行的原型,我们在 ROS2 仿真中成功演示了机械臂基于时序逻辑指令自主完成复杂任务的全过程。例如,在演示中机械臂按照逻辑规范要求先后搬运多个物体,并灵活避开动态加入的障碍物,整个过程均由系统自动规划,无需人工介入。




图 6.1 机械臂按照逻辑规范轨迹修复的路径运行

研究水平提升与后续工作奠基: 通过本人的实践,本项目验证了将时序逻辑用于人机交互控制的可行性,并取得了一定创新:例如实现了任务规范自动修复与路径规划相结合的控制框架。这些成果为课题组在该方向上的研究打开了新思路。我个人也在这一过程中显著提升了科研素养和技术能力,对时序逻辑控制、机器人规划、ROS 系统都有了深入掌握。为后续扩展研究奠定了基础,例如无人机平台的适配以及多机器人协同任务规划,可以直接继承本项目的核心框架展开,实现一种方法、多种平台的通用人机交互控制。

7. 参与研究个人感想

在参与这个基于时序逻辑的机器人路径规划控制研究过程中，我深刻体会到了科研的不确定性与挑战，也获得了巨大的成长与收获。从最初对时序逻辑和机器人控制的基本理解，到逐步实现复杂的路径规划与控制系统，这一过程中每一个环节都让我积累了丰富的技术经验。回顾项目的启动阶段，我对时序逻辑的理解还非常抽象。通过文献研读，特别是在复现 LCRL 和 “Synthesis-Based Repair” 算法时，我不仅加深了对时序逻辑基础理论的掌握，还了解了如何将其与强化学习、路径规划等技术结合，形成一种新的控制策略。

这个过程的技术积累主要体现在对算法深度理解和实施上的突破。尤其在进行算法复现时，我遇到了一系列细节问题：如何精确地将时序约束转化为机器人可执行的轨迹，如何处理来自环境变化的干扰并保持控制系统的一致性。这些问题的解决不仅提升了我的问题分析能力，更让我对科研中“从实践中学”的重要性有了更深刻的认识。这次科研让我体会到，作为一个研究人员，不只是一要追求理论上的最终目标，还要具备处理算法实现细节和系统对接时技术问题的能力。例如，在把复现的算法与 ROS2 平台对接实现路径规划控制时，还原过程中的问题比单纯算法层面的挑战更多。当时我深刻意识到，科研工作往往是细节中见真章。如何通过代码与平台的有效接轨，如何在不同技术栈的协同中调动各领域的知识，是科研的复杂性所在。尤其在调试和性能优化阶段，算法映射到实际控制系统时会遇到很多预期外的困难，例如 ROS2 平台的实时性和并发执行要求，以及机械臂在不同环境下的超时与任务失败等问题。这要求我不停地迭代、反馈与验证，减少系统的不稳定性，最终实现高效的算法平台对接。

此外，通过本项目的研究，我对于团队合作的价值有了更深的体会。在研究的不同阶段，我和我的团队成员共同面对问题、互相协作。在高层路径规划的设计中，我们共同商讨任务分配与优化方式；在 ROS2 节点实现阶段，我与同伴紧密配合，完成了从上层规划到细节执行的精准工作。这种互助合作让我们的工作既更有深度，也更具可操作性。尤其是在面对项目中期的多次实验失败、调试困难时，团队成员之间的讨论与经验分享极大促进了问题的解决。每一次的协作，

都是一次技术上的成长，同时也让我深刻理解到科研不只是个人的战斗，更是团队智慧的结晶。

通过多次实验过程中的跌倒和反思，我意识到，在科研上最重要的成长不仅是在技术层面的突破，更是在面对挫折时不放弃、不退缩的心态构建。特别是在面对算法调优和多个场景实验时，系统的稳定性和鲁棒性总是需要不断优化，虽然前期的工作都很完美，但总会面临越来越复杂的问题。这时，我不仅学到了如何在技术层面突破瓶颈，也深刻体会到了坚持与细心在科研中的重要性。最终，项目在各种严苛条件下顺利演示、取得令人满意的成果时，我的内心也完成了一个由怀疑到自信的蜕变。

总之，这次研究经历不仅让我提升了在智能机器人、时序逻辑控制技术方面的专业能力，还深入体会到了科研的艰难与乐趣。我学会了如何从前人的成果中汲取营养，又如何将理论转化为实践成果；学会了团队合作的重要性，和如何在面对看似无法逾越的技术难关时找到解决方案。这份沉浸式的科研积累将推动我未来不断向更深远的智能控制研究领域迈进，成为我通往更高学术水平的不竭动力源泉。在日后的科研道路上，我会继续秉持严谨求实的工作态度，不断突破自我，迎接更多挑战。

8. 参考文献

- [1] Hasanbeig, H., Kroening, D., Abate, A., "LCRL: Certified Policy Synthesis via Logically-Constrained Reinforcement Learning", QEST, 2022.
- [2] Cai M, Hasanbeig M, Xiao S, et al. Modular deep reinforcement learning for continuous motion planning with temporal logic[J]. IEEE robotics and automation letters, 2021, 6(4): 7973-7980.
- [3] Cai M, Xiao S, Li B, et al. Reinforcement learning based temporal logic control with maximum probabilistic satisfaction[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2021: 806-812.
- [4] Pacheck A, Kress-Gazit H. Physically feasible repair of reactive, linear temporal logic-based, high-level tasks[J]. IEEE Transactions on Robotics, 2023, 39(6): 4653-4670.
- [5] Lv P, Luo G, He Z, et al. Formal Control Synthesis via Safe Reinforcement Learning Under Real-Time Specifications[C]//2024 IEEE 18th International Conference on Control & Automation (ICCA). IEEE, 2024: 478-483.
- [6] Mitta, R., Hasanbeig, H., Wang, J., Kroening, D., Kantaros, Y., Abate, A., "Safeguarded Progress in Reinforcement Learning: Safe Bayesian Exploration for Control Policy Synthesis", AAAI Special Track on Safe, Robust and Responsible AI, 2024.
- [7] Hasanbeig, H. , Abate, A. and Kroening, D., "Cautious Reinforcement Learning with Logical Constraints", International Conference on Autonomous Agents and Multi-agent Systems, 2020.
- [8] Hasanbeig, H. , Kroening, D. and Abate, A., "Deep Reinforcement Learning with Temporal Logics", International Conference on Formal Modeling and Analysis of Timed Systems, 2020.
- [9] Hasanbeig, H. , Kroening, D. and Abate, A., "Towards Verifiable and Safe Model-Free Reinforcement Learning", Workshop on Artificial Intelligence and Formal Verification, Logics, Automata and Synthesis (OVERLAY), 2020.

- [10] Hasanbeig, H. , Kantaros, Y., Abate, A., Kroening, D., Pappas, G. J., and Lee, I., "Reinforcement Learning for Temporal Logic Control Synthesis with Probabilistic Satisfaction Guarantees", IEEE Conference on Decision and Control, 2019.
- [11] Hasanbeig, H. , Abate, A. and Kroening, D., "Logically-Constrained Neural Fitted Q-Iteration", International Conference on Autonomous Agents and Multi-agent Systems, 2019.
- [12] Lim Zun Yuan, Hasanbeig, H. , Abate, A. and Kroening, D., "Modular Deep Reinforcement Learning with Temporal Logic Specifications", CoRR abs/1909.11591, 2019.
- [13] Hasanbeig, H. , Abate, A. and Kroening, D., "Certified Reinforcement Learning with Logic Guidance", CoRR abs/1902.00778, 2019.
- [14] Hasanbeig, H. , Abate, A. and Kroening, D., "Logically-Constrained Reinforcement Learning", CoRR abs/1801.08099, 2018.